

08. 특징 추출

- 특징 추출의 예

6

- 크기장비화
- 이진화

00001100
00010000
00100000
01100000
11000110
11000011
11000001
11111110

특
징
추
출

방법 2: 가로
이등분과 세로
이등분하여 검은
화소의 개수 비율을
특징으로 삼음

방법 1: 화소 각각을 특징으로 삼음
64차원 특징 벡터
 $x = (0, 0, 0, 0, 1, 1, \dots, 1, 1, 0)^T$

$$x_2 = \frac{14}{10}$$

$$\frac{14}{10}$$

$$00001100$$

$$00010000$$

$$00100000$$

$$01100000$$

$$11000110$$

$$11000011$$

$$11000001$$

$$11111110$$

$$6$$

$$18$$

$$x_1 = \frac{6}{18}$$

$$x = (6/18, 14/10)^T$$


또 다른 방법으로는?

- 특징의 우수성 기준

- 분별력 (discriminatory) : 좋은 특징은 서로 다른 부류를 잘 분별해 주어야 함
- 차원 (dimensionality) : 특징 벡터의 차원이 낮을수록 계산 효율이 좋고 차원의 저주에서 멀어진다.

8.1.1 실제 세계의 다양성


- 특징 생성
- 외부의 물리적 패턴을 특징 벡터라는 수학적 표현으로 변환



- 특징 생성 과정은 매우 다양
- 특징 추출은 외부 환경에 맞게 설계해야 하기 때문

8.1.2 특징 추출과 특징 선택

- 센서로 얻은 신호의 다양성
- 영상, 시간성 신호, 측정 벡터



- 다양한 상황

$$X = S, \quad X = e(S), \quad X = S(S), \quad X = S(e(S))$$

8.2 영역에서의 특징 추출


- 영역의 표현

0	1	2	3	4	5
1				1	1
2	1			1	1
3	1	1	1	1	1
4	1	1	1	1	1
5	1	1	1		

(a) 이진 배열 표현

$$\begin{aligned}
 R &= \{(5,0), (4,1), (5,1), (0,2), (4,2), (5,2), \\
 &\quad (0,3), (1,3), (2,3), (3,3), (4,3), (5,3), \\
 &\quad (0,4), (1,4), (2,4), (3,4), (4,4), (1,5), \\
 &\quad (2,5), (3,5)\} \\
 C &= (0,4) + 2 + 2 + 7 + 0 + 0 + 1 + 2 + 1 + 6 + 6 + 5 + 5 + 4 + 3
 \end{aligned}$$

(b) 집합 표현



(c) 체인 코드 표현

그림 8.3 영역의 표현

· 모멘트와 중심 모멘트

$$m_{pq} = \sum_{(x,y) \in R} x^p y^q \quad \bar{m}_{pq} = \sum_{(x,y) \in R} (x - \bar{x})^p (y - \bar{y})^q$$

· 여러 가지 특징들

면적 $a = m_{00}$

둘레 $P = n_{even} + n_{odd} \sqrt{2}$

중점 $(\bar{x}, \bar{y}) = \left(\frac{m_{10}}{a}, \frac{m_{01}}{a}\right)$

이 때 n_{even} 짝수를 갖는 체인의 개수
 n_{odd} 홀수를 갖는 체인의 개수

행분산 $V_{rr} = \frac{\bar{m}_{20}}{a}$

둥근정도 $r = \frac{4\pi a}{P^2}$ ←area
 ←perimeter

열분산 $V_{cc} = \frac{\bar{m}_{02}}{a}$

혼합분산 $V_{rc} = \frac{\bar{m}_{11}}{a}$

· 불변 특성

- 이동 불변 (translation invariant)

특징 a 는 영역 ROI 다른 위치로 이동해도 값이 변하지 X

중점을 나타내는 특징 \bar{x} 와 \bar{y} 는 이동 불변이지 않다.

- 크기 불변 (scale invariant)

영역의 크기가 중점을 기준으로 변한다면 중점은 그대로 유지된다.

특징 a 는 크기 불변 X

- 회전 불변 (rotation invariant)

\bar{x} 와 \bar{y} 는 자신을 중심으로 회전하면 회전 불변이지만, 다른 점을 중심으로 회전하면 회전 불변 X

예제 8.1 모양 특징의 추출

1번 영역의 특징




그림 8.5 세 개의 영역

면적 $a=20$

$$\text{중점 } (\bar{x}, \bar{y}) = \left(\frac{\sum_{\text{영역 } X} x}{20}, \frac{\sum_{\text{영역 } X} y}{20} \right)$$

$$= (x\text{의 합}/20, y\text{의 합}/20) = (2.7, 3.05)$$

$$\text{행 분산 } V_{rr} = \frac{\sum_{\text{영역 } X} (x - 2.7)^2}{20} = 3.01$$

$$\text{열 분산 } V_{cc} = \frac{\sum_{\text{영역 } X} (y - 3.05)^2}{20} = 1.848$$

$$\text{혼합 분산 } V_{rc} = \frac{\sum_{\text{영역 } X} (x - 2.7)(y - 3.05)}{20} = -1.135$$

$$\text{둘레 } P = 10 + 6\sqrt{2} = 18.485$$

$$\text{둥근 정도 } r = \frac{4\pi \times 20}{18.485^2} = 0.736$$

	면적 a	중점 (\bar{x}, \bar{y})	행 분산 V_{rr}	열 분산 V_{cc}	혼합 분산 V_{rc}	둘레 P	둥근 정도 r
영역 1	20	(2.7, 3.05)	3.01	1.848	-1.135	18.485	0.736
영역 2	12	(4.5, 8.5)	0.917	0.917	0.0	9.657	1.617
영역 3	18	(9.5, 6)	0.25	6.667	0.0	18	0.698

원이 디지털

공간에 균사화되어

있기 때문에

발생하는 현상

→ 원이 커지면 오류
적어짐

8.2.2 투영과 프로파일 특징

• 투영(projection) 특징

행 투영 $h_i =$ 행 i 에 있는 1의 개수, $0 \leq i \leq N-1$

열 투영 $v_j =$ 열 j 에 있는 1의 개수, $0 \leq j \leq M-1$

$\rightarrow N \times M$ 차원의 특징 벡터를 얻게 됨

- ⑥ 몇개 건너 투영하거나, 이웃한 투영 몇 개의 평균을 구하는 방법으로 특징의 개수 줄일 수 있음. 평균을 사용하면 잡음에 둔감해지는 효과

예제 8.2

	0	1	2	3	4	5
0						1
1					1	1
2	1				1	1
3	1	1	1	1	1	1
4	1	1	1	1	1	
5		1	1	1		

열 투영

특징 벡터 $x = (3, 3, 3, 3, 4, 4, 1, 2, 3, 6, 5, 3)^T$

두개의 투영 평균하면, $x = (3, 3, 4, 1.5, 4.5, 4)^T$

그림 8.6 투영 특징

- 프로파일 특징

- $2(N+M)$ 차원의 특징 벡터를 얻게 됨

상 프로파일 $t_j =$ 위에서 열 j 를 바라보았을 때 처음 1까지의 거리,

$$0 \leq j \leq M-1$$

우 프로파일 $r_i =$ 오른쪽에서 행 i 를 바라보았을 때 처음 1까지의 거리,

$$0 \leq i \leq N-1$$


하 프로파일 $b_j =$ 아래에서 열 j 를 바라보았을 때 처음 1까지의 거리,

$$0 \leq j \leq M-1$$

좌 프로파일 $l_i =$ 왼쪽에서 행 i 를 바라보았을 때 처음 1까지의 거리,

$$0 \leq i \leq N-1$$

예제 8.3 프로파일 특징의 추출



특징 벡터 $\chi = (2, 3, 3, 3, 1, 0, 1, 0, 0, 1, 2, 2, 1, 0, 0, 0, 1, 1, 0, 0, 0, 4, 5)^T$

아웃한 3개 평균? $\chi = (2.66, 1.33, 0.11, 1, 0.33, 0.33, 3)^T$

그림 8.7 프로파일 특징


8.3 변환을 이용한 특징

- 파형 (waveform) 신호에서의 특징 추출


예) 지진파, 기계 진동파, 수중파, 음파, 주식 곡선 등

- 파형에서 어떻게 특징을 추출할 것인가?


→ 파형은 기저 함수의 선형 결합으로 표현 가능: 선형 결합의 계수를 특징으로 함. 계수를 어떻게 구할 것인가?




(a) 신호 $s_1(x) = 0.5g_1(x) + 1.5g_2(x)$



(b) 신호 $s_2(x) = 1.5g_1(x) + 0.5g_2(x)$



(c) 기저 함수 $g_1(x) = \sin(x)$



(d) 기저 함수 $g_2(x) = 0.25\sin(4x)$

$$S_1(x) = 0.5g_1(x) + 1.5g_2(x)$$
$$S_2(x) = 1.5g_1(x) + 0.5g_2(x)$$

신호 S_1 의 특징벡터 $= (0.5, 1.5)^T$

신호 S_2 의 특징벡터 $= (1.5, 0.5)^T$

→ 기저함수의 계수는 어떻게 구할건데?

이산 푸리에 변환

그림 8.8 입력 신호는 기저 함수의 선형 결합으로 표현할 수 있음

8.3.1 푸리에 변환

· 이산 푸리에 변환

→ 입의의 입력 신호를 다양한 주파수를 갖는 주파수들의 합으로 분해하여 표현


신호를 $S = (S(0), S(1), \dots, S(n-1))^T$ 로 표현할 때,

푸리에 변환 $f(u)$ 는 시간 공간을 주파수 공간으로 바꾸어 준다.

$$f(u) = \frac{1}{\sqrt{n}} \sum_{i=0}^{n-1} S(i) \exp(-j \frac{2\pi u i}{n}), \quad u=0, \dots, n-1$$

예제 8.4 이산 푸리에 변환

$$S = (1.7, 0.6, 1.5, 1.2)^T$$



$$\begin{aligned} f(0) &= 0.5(1.7e^0 + 0.6e^0 + 1.5e^0 + 1.2e^0) \\ &= 2.5 \end{aligned}$$

이처럼 어떤 입력 신호든 간에 다
Sin, Cos 주기함수들의 합으로
분해 가능

$$f(0) = 0.5(1.7e^0 + 0.6e^0 + 1.5e^0 + 1.2e^0) = 2.5 + j0$$

$$\begin{aligned} f(1) &= 0.5(1.7e^0 + 0.6e^{-j\pi/2} + 1.5e^{-j2\pi/2} + 1.2e^{-j3\pi/2}) \\ &= 0.5(1.7 + 0.6(\cos(-\pi/2) + j\sin(-\pi/2)) + 1.5(\cos(-2\pi/2) \\ &\quad + j\sin(-2\pi/2)) + 1.2(\cos(-3\pi/2) + j\sin(-3\pi/2))) \\ &= 0.5((1.7 + 0.6\cos(-\pi/2) + 1.5\cos(-2\pi/2) + 1.2\cos(-3\pi/2)) \\ &\quad + j(0.6\sin(-\pi/2) + 1.5\sin(-2\pi/2) + 1.2\sin(-3\pi/2))) = 0.1 + j0.3 \end{aligned}$$

$$f(2) = 0.5(1.7e^0 + 0.6e^{-j2\pi/2} + 1.5e^{-j4\pi/2} + 1.2e^{-j6\pi/2}) = 0.7 + j0$$

$$f(3) = 0.5(1.7e^0 + 0.6e^{-j3\pi/2} + 1.5e^{-j6\pi/2} + 1.2e^{-j9\pi/2}) = 0.1 - j0.3$$

u	실수부	허수부
0	2.5	0
1	0.1	0.3
2	0.7	0
3	0.1	-0.3

- 푸리에 특징

- 파워 스펙트럼의 값을 특징으로 취함

$$P(u) = \sqrt{\text{real}(f(u))^2 + \text{imag}(f(u))^2}, u = 0, \dots, n-1$$

여제 8.5 푸리에 특징

$$P(0) = (2.5^2 + 0^2)^{1/2} = 2.5$$

$$P(1) = (0.1^2 + 0.3^2)^{1/2} = 0.316$$

$$P(2) = (0.1^2 + 0^2)^{1/2} = 0.1$$

$$P(3) = (0.1^2 + (-0.3)^2)^{1/2} = 0.316$$

즉, 아래와 같은 4차원 특징 벡터를 얻게 된다.

$$\mathbf{x} = (2.5, 0.316, 0.1, 0.316)^T$$

• 푸리에 특징 알고리즘

- d개의 특징을 추출하고자 하면 $P(0), P(1), \dots, P(d-1)$ 을 추한다.
- 왜냐하면 나가 커질수록 $P(u)$ 는 급속도로 작아지므로

알고리즘 [8.1]

푸리에 특징 추출

입력: 신호 s , 필요한 특징 개수 d

출력: d 차원의 특징 벡터 \mathbf{x}

알고리즘:

1. FFT 알고리즘을 이용하여 s 의 푸리에 변환을 구한다.
2. (8.20)으로 파워 스펙트럼 $p(u)$, $u=0, \dots, n-1$ 을 구한다.
3. $\mathbf{x} = (p(0), p(1), \dots, p(d-1))^T$:

• 2차 푸리에 변환

$$f(u, v) = \frac{1}{n} \sum_{i=0}^{n-1} \sum_{k=0}^{n-1} S(i, k) \exp\left(-j \frac{2\pi(ui+vk)}{n}\right), \quad u=0, \dots, n-1 \quad (8.21)$$
$$v=0, \dots, n-1$$

$$\text{파워 스펙트럼 } P(u, v) = \sqrt{\text{real}(f(u, v))^2 + \text{imag}(f(u, v))^2} \quad (8.22)$$

- 퓨리에 기술자
- 2차원 퓨리에 변환은 $n \times n$ 영상에 적용할 수 있다.
- 영역 경계 상의 점을 복소수로 표현하는 뒤에 2차원 퓨리에 변환 적용

그림 8.3(a)에 있는 영역의 경계 표현:

$$(0, 4) - (0, 3) - (0, 2) - (1, 3) - (2, 3) - (3, 3) - (4, 2) - (4, 1) - \\ (5, 0) - (5, 1) - (5, 2) - (5, 3) - (4, 4) - (3, 5) - (2, 5) - (1, 5)$$

$$d(i) = x_i + jy_i, 0 \leq i \leq n-1$$

ex) $d(4) = 2 + j3$ 처럼 표현


퓨리에 기술자 $f(u) = \frac{1}{\sqrt{n}} \sum_{i=0}^{n-1} d(i) e^{-j \frac{2\pi u i}{n}}, u = 0, \dots, n-1$

8.4 시계열 신호에서의 특징 추출

시계열 형태 (지진파, 음성파, 주식 시세) \rightarrow 동적인 성질을 가지므로 정적인

영상과 다른 추출 방식 필요 : ① 주로 퓨리에 변환 이용

② 보통 신호를 frame 단위로 나눔



각각의 프레임에서 특징 벡터 추출

시계열 신호에서 추출한 특징 벡터의 열 $(x_1, x_2, \dots, x_n)^T$

i번째 frame의 신호를 s_i 로 표기하자. 특징 추출을 위한 아주 간단한 방법은 s_i 를 알고리즘 [8.1]에 입력하여 퓨리에 특징 벡터 x_i 를 구하는 것이다. 특징 벡터는 (8.25)와 같이 표현할 수 있다.

$P_i(j)$ 는 i번째 프레임에서 얻은 파워 스펙트럼의 j번째 값이다.

$$x_i = (P_i(0), P_i(1), \dots, P_i(d-1))^T$$

퓨리에 특징보다 분별력에서 우수하여 보다 널리 쓰이는 cepstrum 특징이 있다. ↗

알고리즘 [8.2]

캡스터럼 특징 추출

입력: 신호 $s = (s(0), s(1), \dots, s(n-1))$, 확장 프레임 길이 m , 필요한 특징 개수 d

출력: d 차원의 특징 벡터 x

알고리즘:

1. s 의 뒤에 $m-n$ 개의 0을 붙여 $s' = (s(0), s(1), \dots, s(n-1), 0, 0, \dots, 0)$ 을 구한다.
2. s' 에 대해 (8.19)로 이산 퓨리에 변환을 수행하여 $f(u)$ 를 구한다.
3. $f(u)$ 의 파워 스펙트럼에 로그를 취하고 그 결과에 대해 퓨리에 역 변환을 취한다.
4. 3에서 구한 결과를 특징 벡터 x 로 취한다.

8.5 주성분 분석

- 혼연 집합을 이용하여 매개 변수를 추정하고 그것을 이용하여 특징을 추출함
- 정보 손실을 최소화하는 조건에서 차원 축소
- Karhunen-Loeve(KL) 변환 또는 Hotelling 변환이라고 부름

8.5.1 동기

• 주성분 분석의 동기

- U 는 '정보 손실을 최소화하며' 신호 S 를 보다 낮은 차원의 특징벡터 x 로 변환 ($d < D$)

- 변환 행렬 U 는 $D \times D$ 행렬 (신호 S 는 D 차원, 특징벡터 x 는 d 차원)

- 두가지 문제

① 차원 축소를 어떻게 표현할 것인가?

② 정보 손실을 어떻게 수양화할 것인가?

$$x = e(s; U) = Us$$




그림 8.12 특징 추출 방법의 비교

• 차원 축소의 표현

- D 차원 단위벡터 u 축으로의 투영

$$\hat{x} = u^T s$$




그림 8.13 투영에 의해 2 차원 공간을 1 차원 공간으로 축소

- 정보 손실의 공식화
- 원래 훈련 집합이 가진 정보란 무엇일까?
- 샘플들 간의 거리, 그들 간의 상대적인 위치
- PCA는 샘플들이 원래 공간에 '퍼져있는 정도를' 변환된 공간에서 얼마나 잘 유지하느냐를 척도로 삼음
→ 이 척도는 변환된 공간에서 샘플들의 분산으로 측정

변환된 샘플들의 분산을 최대화하는 축(즉 단위 벡터 u)을 찾아라.

예제 8.6 변환 공간에서의 분산

원래 샘플 $S_1 = (2, 1)^T, S_2 = (2, 4)^T, S_3 = (4, 1)^T, S_4 = (4, 3)^T$

$U^T = (1, 0)$ 축으로 투영된 샘플

$$\hat{x}_1 = (1, 0) \begin{pmatrix} 2 \\ 1 \end{pmatrix} = 2, \hat{x}_2 = (1, 0) \begin{pmatrix} 2 \\ 4 \end{pmatrix} = 2 \quad) \text{분산: } 1.0$$

$$\hat{x}_3 = (1, 0) \begin{pmatrix} 4 \\ 1 \end{pmatrix} = 4, \hat{x}_4 = (1, 0) \begin{pmatrix} 4 \\ 3 \end{pmatrix} = 4$$

$U^T = (\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}})$ 축으로 투영된 샘플

$$\hat{x}_1 = (\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}) \begin{pmatrix} 2 \\ 1 \end{pmatrix} = \frac{3}{\sqrt{2}}, \hat{x}_3 = (\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}) \begin{pmatrix} 4 \\ 1 \end{pmatrix} = \frac{5}{\sqrt{2}}$$

$$\hat{x}_2 = (\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}) \begin{pmatrix} 2 \\ 4 \end{pmatrix} = \frac{6}{\sqrt{2}}, \hat{x}_4 = (\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}) \begin{pmatrix} 4 \\ 3 \end{pmatrix} = \frac{7}{\sqrt{2}}$$

분산: 1.0938 더 좋은 축이 있나?

8.5.2 알고리즘과 응용

- 투영된 점의 평균과 분산

$$\hat{x}_i, 1 \leq i \leq N \text{의 평균: } \bar{x} = \frac{1}{N} \sum_{i=1}^N \hat{x}_i = \frac{1}{N} \sum_{i=1}^N u^T s_i = u^T \left(\frac{1}{N} \sum_{i=1}^N s_i \right) = u^T \bar{s} \quad (8.29)$$

$$\hat{x}_i, 1 \leq i \leq N \text{의 분산: } \sigma^2 = \frac{1}{N} \sum_{i=1}^N (\hat{x}_i - \bar{x})^2 = \frac{1}{N} \sum_{i=1}^N (u^T s_i - u^T \bar{s})^2 \quad (8.30)$$

즉, (8.30)의 분산 σ^2 을 최대화하는 u 를 찾아라.

u 가 단위벡터라는 조건을 이용하면 $u^T u = 1$ 이라는 조건을 만들 수 있다.

조건부 최적화 문제로 다시 쓰면,

- L 은 라그랑제 함수, λ 는 라그랑제 승수

$$L(u) = \frac{1}{N} \sum_{i=1}^N (u^T s_i - u^T \bar{s})^2 + \lambda (1 - u^T u) \text{를 최대화하는 } u \text{를 찾아라.} \quad (8.31)$$

$$\partial L(u) / \partial u = \frac{\partial}{\partial u} \left(\frac{1}{N} \sum_{i=1}^N (u^T s_i - u^T \bar{s})^2 + \lambda (1 - u^T u) \right) / \delta u$$

$$= \frac{2}{N} \sum_{i=1}^N (u^T s_i - u^T \bar{s}) (s_i - \bar{s}) - 2\lambda u$$

$$= 2u^T \left(\frac{1}{N} \sum_{i=1}^N (s_i - \bar{s})^2 \right) - 2\lambda u$$

$$= 2u^T \bar{s} - 2\lambda u \quad \xrightarrow{\text{공분산 행렬 (대칭임!)}}$$

$$= 2\bar{s}^T u - 2\lambda u = 0$$

$$\uparrow \bar{s}^T u = \uparrow \lambda u \rightarrow u \text{는 공분산 행렬 } \bar{s}^T \text{의 고유 벡터, } \lambda \text{는 고유값}$$

고유벡터: 선형 변환 A 에 의한 변환 결과가 자기 자신의
상수배가 되는 0이 아닌 벡터

행공간에 속적인 벡터

예제 8.7 최대 분산을 갖는 축

$X = \{(2, 1)^T, (2, 4)^T, (4, 1)^T, (4, 3)^T\}$ 훈련집합

$$\lesssim = \begin{pmatrix} 1.000 & -0.250 \\ -0.250 & 1.688 \end{pmatrix} \quad \text{공분산 행렬}$$

고유값 $\lambda_1 = 1.7688$, $U_1^T = (-0.3092, 0.9510)$

$\lambda_2 = 0.9187$, $U_2^T = (-0.9510, -0.3092)$

$U_1^T = (-0.3092, 0.9510)$ 으로 투영된 특징벡터

$$\hat{x}_1 = (-0.3092, 0.9510) \begin{pmatrix} 2 \\ 1 \end{pmatrix} = 0.3326$$

$$\hat{x}_2 = 3.1856 \quad \hat{x}_3 = -0.2858 \quad \hat{x}_4 = 1.6162$$

평균: $(-0.3092, 0.9510) \begin{pmatrix} 3 \\ \frac{9}{4} \end{pmatrix} = 1.2122$

분산: 1.7688

지금까지 하나의 축으로 투영하는 상황설명. 실제에서는 D차원을 d차원으로 줄이는 것이 목적이므로 d개의 축을 찾아야 한다.

고유벡터의 성질에 따라 이들은 모두 수직(orthogonal)이다.

즉, $U_i^T U_j = 0, i \neq j$ 이다. 또한, 고유벡터는 고유값을 갖는데

고유값이 클수록 중요도가 크다. 따라서 고유값에 따라 정렬을 하고, 상위 d개의 고유벡터를 선정하면 된다.

이들을 u_1, u_2, \dots, u_d 로 표기하자. 이들 각각을 주성분 (principal component) 라 부른다. U 의 한 행을 차지하는 u_i^\top 은 크기가 d 인 행 벡터이다. 따라서 V 는 $d \times D$ 행렬이다.

$$U = \begin{pmatrix} u_1^\top \\ u_2^\top \\ \vdots \\ u_d^\top \end{pmatrix}$$

아제) PCA로 구한 변환 행렬 V 를 이용하여 신호 S 를 특징 벡터 x 로 변환하는 식이다.

알고리즘 [8.3] PCA에 의한 변환 행렬 구함

입력: 훈련 집합 $X = \{s_1, s_2, \dots, s_N\}$, 원하는 차원 d

출력: 변환 행렬 U , 평균 벡터 \bar{s}

알고리즘:

1. $\bar{s} = \frac{1}{N} \sum_{i=1}^N s_i$ // X 의 평균 벡터
2. for ($i = 1$ to N) $s'_i = s_i - \bar{s}$; // 평균 벡터를 빼줌
3. $s'_i, 1 \leq i \leq N$ 의 공분산 행렬 Σ 를 구한다.
4. Σ 의 고유 벡터와 고유 값을 구한다. 어케 구하나?
5. 고유 값 기준으로 가장 큰 d 개의 고유 벡터를 선택한다.
6. (8.34)로 변환 행렬 U 를 만든다.
7. return U, \bar{s} ;

) 조표계의 원점이 평균 벡터 \bar{s} 와 일치하도록 해주는 전처리 과정

알고리즘 [8.4] PCA에 의한 특징 추출

입력: 변환 행렬 U , 평균 벡터 \bar{s} , 샘플 s

출력: 특징 벡터 x

알고리즘:

1. $s = s - \bar{s}$; // 샘플에서 평균 벡터를 뺀다.
2. $x = Us$; // (8.35)
3. return x

· PCA의 응용

① 특징 추출(얼굴인식) → 영역분할의 어려움으로 성능 한계에 직면한
것이 사실

② 특징 벡터의 차원 축소

PCA : 훈련집합 샘플들은 부류 정보 X → 원래 특징 벡터가
가진 정보의 손실을 최소화하는 변환행렬을 찾음

LDA : 훈련집합 부류정보 O → 변환공간에서 서로 다른
부류가 가장 잘 분별될 수 있는 변환행렬을 찾음

③ 데이터 압축

④ 시각화

B.5.3 사례 연구: 고유 얼굴

얼굴 인식은 눈, 코, 입 등의 정확한 영역분할이 어려워 정확한
특징 값을 얻는다는 보장이 없음.

→ 1990년대 초 Turk와 Pentland가 싱다른 방법 제안:

고유 얼굴 (eigenface)

2차원 영상 표현을 1차원 선형 표현으로 바꾼다!

$$S = (S_1, S_2, \dots, S_n)^T = (I[1][1], I[1][2], \dots, I[1][n], I[2][1], \dots, I[n][n-1], I[n][n])^T \quad (B.36)$$

(얼굴 영상 집합 $I = \{I_1, I_2, \dots, I_N\}$, I 는 $n \times n$ 크기의 영상,
 $I[r][c]$, $1 \leq r, c \leq n$ 으로 표기)

• 분류기 학습과 인식단계

1. $D = n^2$ 차원을 몇 차원으로 줄일지 결정(d)
 2. X와 d를 알고리즘 [8.3]의 입력으로 주어 변환 행렬 U와 특징 벡터 S를 구한다.
 3. (분류기 학습) X의 샘플 각각을 알고리즘 [8.4]에 넣어 특징 벡터 추출
 4. (분류기 학습) X' 로 분류기 훈련(이때 분류기는 선경망, SVM, k-NN, 트리 분류기 등 어느 것이라도 좋다)
 5. (인식) 인식을 해야하는 새로운 영상이 들어오면 (8.36)으로 신호 S 표현을 바꾸고 이를 알고리즘 [8.4]에 넣어 특징 벡터 x 를 추출. x 를 분류기에 넣어 인식한다.
-
- 변환 행렬 U를 구성하는 고유 벡터 u_i 를 고유 얼굴이라 부른다.

8.6 Fisher의 선형 분별

- 특징 추출이 아닌 분류기 설계에 해당
- but, PCA와 유리가 비슷하여 이것에 머치
- PCA와 Fisher LD는 목표가 다른
 - PCA는 정보 손실 최소화(샘플의 부류 정보 사용X)
 - Fisher LD는 분별력을 최대화(샘플의 부류 정보 사용O)

• 유리

- 축으로의 투영 $y = w^T x$

- 세 개의 축 중에 어느것이 분별력 관점에서 가장 유리한가?




그림 8.15 2 차원 공간을 1 차원 공간으로 투영 (Fisher의 LD)

• 문제 공식화

- 유리한 정도를 어떻게 수식화할까?
- 가장 유리한 축을 어떻게 찾을 것인가?

- 기본 아이디어
- "같은 부류의 샘플은 모여있고 다른 부류의 샘플은 멀리 떨어져 있을 수록 유리하다"
- 부류간 퍼짐 (between-class scatter)
- 부류내 퍼짐 (within-class scatter)

N_i 는 w_i 에 속하는 샘플의 개수이다.

$$m_i = \frac{1}{N_i} \sum_{x \in w_i} x \quad (\text{원래 공간에서의 평균 점}) \quad (8.38)$$

$$\begin{aligned} \bar{m}_i &= \frac{1}{N_i} \sum_{y \in w_i} y \quad (\text{투영 후의 평균 점}) \quad (8.39) \\ &= \frac{1}{N_i} \sum_{x \in w_i} w^T x \\ &= w^T m_i \end{aligned}$$

$$\text{부류간 퍼짐} = |\bar{m}_1 - \bar{m}_2| = |w^T m_1 - w^T m_2| = |w^T(m_1 - m_2)| \quad (8.40)$$

$$\bar{s}_i^2 = \sum_{y \in w_i} (y - \bar{m}_i)^2 \quad (8.41)$$

$$\text{부류내 퍼짐} = \bar{s}_1^2 + \bar{s}_2^2 \quad (8.42)$$

• 목적함수 $J(w)$

$$J(w) = \frac{\text{부류간 퍼짐}}{\text{부류내 퍼짐}} = \frac{|\bar{m}_1 - \bar{m}_2|^2}{\bar{s}_1^2 + \bar{s}_2^2} \quad (8.43)$$

$J(w)$ 를 최대화하는 w 를 찾아라.

• 분자와 분모를 다시 쓰면,

$$\begin{aligned} \textcircled{(분모)} \quad & \bar{s}_1^2 + \bar{s}_2^2 = \sum_{y \in w_1} (y - \bar{m}_1)^2 + \sum_{y \in w_2} (y - \bar{m}_2)^2 \\ &= \sum_{x \in w_1} (w^T x - w^T m_1)^2 + \sum_{x \in w_2} (w^T x - w^T m_2)^2 \\ &= \sum_{x \in w_1} w^T (x - m_1)(x - m_1)^T w + \sum_{x \in w_2} w^T (x - m_2)(x - m_2)^T w \\ &= w^T S_w w \quad (8.44) \end{aligned}$$

이 때 $\underline{S_w} = s_1 + s_2$ 이고, $s_i = \sum_{x \in w_i} (x - m_i)(x - m_i)^T$

부류내 퍼짐 행렬

$$\begin{aligned} \textcircled{(분자)} \quad & |\bar{m}_1 - \bar{m}_2|^2 = (w^T m_1 - w^T m_2)^2 \\ &= w^T (m_1 - m_2)(m_1 - m_2)^T w \\ &= w^T S_B w \quad (8.45) \end{aligned}$$

이 때 $\underline{S_B} = (m_1 - m_2)(m_1 - m_2)^T$

부류간 퍼짐 행렬

$$J(w) = \frac{w^T S_B w}{w^T S_w w}$$

$\frac{\partial J(w)}{\partial w} = 0$ 으로 두고 풀면,

$$(w^T S_w w) S_B w = (w^T S_B w) S_w w$$

$$(W^T S_B W) S_W W = (W^T S_W W) S_B W$$

$$(W^T S_B W) S_W W = (W^T S_W W) \alpha_1 (m_1 - m_2)$$

$$S_W W = \frac{W^T S_W W}{W^T S_B W} \alpha_1 (m_1 - m_2)$$

$$S_W W = \alpha_2 \alpha_1 (m_1 - m_2)$$

$$W = \alpha_2 \alpha_1 W^{-1} (m_1 - m_2)$$

$$W = \alpha_1 S_W^{-1} (m_1 - m_2)$$

여제 1 B.B

W₁ 샘플(파랑): $x_2 = (2, 4)^T, x_4 = (4, 3)^T$

W₂ 샘플(검정): $x_1 = (2, 1)^T, x_3 = (4, 1)^T$

$$m_1 = (3, 3, 5)^T \quad m_2 = (3, 1)^T$$

$$\begin{aligned} S_W &= S_1 + S_2 = \left[\begin{pmatrix} -1 \\ 0.5 \end{pmatrix} (-1, 0.5) + \begin{pmatrix} 1 \\ -0.5 \end{pmatrix} (1, -0.5) \right] + \\ &\quad \left[\begin{pmatrix} 1 \\ 0 \end{pmatrix} (-1, 0) + \begin{pmatrix} 1 \\ 0 \end{pmatrix} (1, 0) \right] = \begin{pmatrix} 4 & -1 \\ -1 & 0.5 \end{pmatrix} \end{aligned}$$

$$S_W^{-1} = \begin{pmatrix} 0.5 & 1 \\ 1 & 4 \end{pmatrix}$$

$$W = \alpha \begin{pmatrix} 0.5 & 1 \\ 1 & 4 \end{pmatrix} \begin{pmatrix} 0 \\ 2.5 \end{pmatrix} = \alpha' \begin{pmatrix} 1 \\ 4 \end{pmatrix}$$

W 의 크기 으시 가능하므로,

$$W = \left(\frac{1}{\sqrt{17}}, \frac{4}{\sqrt{17}} \right)^T = (0.24254, 0.97014)^T$$

8. 7 실용적 관점

8.7.1 특징 결합

- 특징의 분별력 한계

- 그림 8.17은 필기 숫자의 예
- 그래도 만족스럽다면 그것으로

특징설계 원칙

- 특징이 만족스럽지 않다면,
 - 버리고 다른 특징을 채택
 - 또는 기존 특징에 새로운 특징을 추가하는 특징 결합

• 특징이 가지는 정보

- 전역 정보

ex) 검은 화소 비율

- 지역 정보

ex) 프로파일

$x_2 = 0.9090$
10 11
00001110
00010010
00100000
01000000
10011000
10100110
01000011
00111100

$$\mathbf{x} = (0.5, 0.9090)^T$$

(a) 경향을 따르는 상황

$x_2 = 1.0$
15 15
00011111
00110011
01110011
11000000
10011000
10100110
01000011
00111100

$$\mathbf{x} = (1.1429, 1.0)^T$$

(b) 경향을 어기는 상황

그림 8.17 특징의 성질 (숫자 부류 6)




그림 8.7 프로파일 특징

8. 7. 2 특징 전처리

- 거리 개념이 없는 특징의 변환

- 예) 혈액형, 직업, 성씨 등

- 거리 개념이 없는 특징 x_i 가 n개의 값을 갖는다면

x_i 를 $x_{i1}, x_{i2}, \dots, x_{in}$ 으로 확장

- $x_{i1}, x_{i2}, \dots, x_{in}$ 중 하나만 1을 가지고 나머지는 0

- 특징 값의 정규화

- 선형변환

△ 새로운 동적 범위

$$\tilde{x}_i = low_i + \frac{high_i - low_i}{\max_i - \min_i} (x_i - \min_i)$$

$\hookrightarrow x_i$ 의 동적 범위

- 통계에 의한 변환 (평균은 0, 표준편차는 1을 가지도록 정규화)

$$\tilde{x}_i = \frac{x_i - \bar{x}_i}{\sigma_i}$$

- 손실 특징의 보충

데이터 손실이 있을 때,

① 훈련집합이 충분히 큰 경우 손실 특징 가진 샘플 제거

② 또는 다른 샘플로 평균을 구하여 손실 샘플에 채움